



ΕΘΝΙΚΟ ΜΕΤΣΟΒΙΟ ΠΟΛΥΤΕΧΝΕΙΟ

**ΣΧΟΛΗ ΗΛΕΚΤΡΟΛΟΓΩΝ ΜΗΧΑΝΙΚΩΝ ΚΑΙ ΜΗΧΑΝΙΚΩΝ ΥΠΟΛΟΓΙΣΤΩΝ
ΤΟΜΕΑΣ ΣΥΣΤΗΜΑΤΩΝ ΜΕΤΑΔΟΣΗΣ ΠΛΗΡΟΦΟΡΙΑΣ ΚΑΙ ΤΕΧΝΟΛΟΓΙΑΣ ΥΛΙΚΩΝ**

**«Ανάπτυξη mobile εφαρμογής για την αυτόματη διάγνωση
καρκίνου του δέρματος μέσω λήψης φωτογραφιών»**

Εξαμηνιαία Εργασία

στο μάθημα «Τεχνολογίες Κινητής και Ηλεκτρονικής Υγείας»

των φοιτητών

**Αλεξανδρόπουλου Σταμάτη, Α.Μ.: 03117060
Μαρούλη Γεωργίας-Αναστασίας, Α.Μ.: 03116146
Μπακιρτζή Χριστίνας, Α.Μ.: 03116013**

Διδάσκοντες: Δ. Κουτσούρης, Κ. Νικήτα, Γ. Ματσόπουλος

Υπεύθυνος Άσκησης: Ι. Βεζάκης

Αθήνα, Ιούνιος 2021

Περίληψη

Ο καρκίνος του δέρματος αποτελεί ένα ιδιαίτερα σημαντικό πρόβλημα στη σημερινή εποχή, καθώς αποτελεί τον πιο συχνό τύπο καρκίνου. Πρόκειται για μια κακοήγη βλάβη του δέρματος, η οποία εμφανίζεται συχνότερα στην περιοχή του δέρματος που εκτίθεται στην ηλιακή ακτινοβολία. Υπάρχουν τρεις τύποι καρκίνου (το βασικοκυτταρικό καρκίνωμα, το ακανθοκυτταρικό καρκίνωμα και το μελάνωμα), οι οποίοι είναι δυνατόν τόσο να προληφθούν, όσο και να αντιμετωπιστούν, τουλάχιστον στην πλειοψηφία των περιπτώσεων. Για να θεραπευτεί όμως ο καρκίνος αυτός, πρέπει η διάγνωση να γίνει σε πρώιμα στάδια της νόσου, γεγονός δύσκολο, αφού η ασυμπτωματική περίοδος μπορεί να διαρκέσει μήνες ή χρόνια. Σκοπός της εργασίας αυτής είναι να συμβάλει στην έγκαιρη αυτή διάγνωση, με τη δημιουργία μιας κινητής εφαρμογής, η οποία θα χρησιμοποιεί μηχανική μάθηση και θα διακρίνει μεταξύ κοινών σπύλων (ελιές) και κακοηθών δερματικών βλαβών σε φωτογραφίες δέρματος. Η ανάπτυξη της εφαρμογής αυτής αναδεικνύει κατά πόσο ένα νευρωνικό δίκτυο μπορεί να οδηγήσει σε σωστά αποτελέσματα, δηλαδή, στη συγκεκριμένη περίπτωση, να αναγνωρίσει με αξιοπιστία μελανώματα από κοινές ελιές. Επομένως, για την εκπόνηση της εργασίας αυτής πραγματοποιείται τόσο βιβλιογραφική ανασκόπηση με σκοπό την αναζήτηση δεδομένων, για το θεωρητικό υπόβαθρο της εργασίας, όσο και συγγραφή κώδικα για τη δημιουργία της εφαρμογής.

Λέξεις Κλειδιά

Καρκίνος Δέρματος, Ανίχνευση, Λήψη Φωτογραφιών, Μηχανική Μάθηση, Κινητή Εφαρμογή

Περιεχόμενα

1 Εισαγωγή.....	7
1.1 Καρκίνος του Δέρματος.....	7
1.2 Παράγοντες.....	7
1.3 Συμπτώματα.....	8
1.4 Διάγνωση και Θεραπεία.....	9
1.5 Πρόληψη Καρκίνου.....	10
1.6 Εφαρμογές Έγκαιρης Διάγνωσης.....	10
2 Προηγούμενες Έρευνες.....	11
2.1 Εμπόδια.....	11
2.2 Προσεγγίσεις.....	12
2.3 Μοντέλα.....	12
3 Μοντέλο Μηχανικής Μάθησης.....	17
3.1 Βασικές έννοιες.....	17
3.1.1 Μηχανική Μάθηση.....	17
3.1.2 Transfer Learning.....	17
3.2 Εργαλεία.....	19
3.2.1 Google Colaboratory.....	19
3.2.2 Keras.....	19
3.3 Ανάλυση του μοντέλου.....	19
3.3.1 Dataset και επεξεργασία δεδομένων.....	20
3.3.2 Επιλογή αρχιτεκτονικής δικτύου.....	20
3.3.3 EfficientNet-B0.....	21
3.3.4 Adam Optimizer.....	22
3.4 Αποτελέσματα.....	23
3.4.1 Loss - Accuracy.....	23
3.4.2 Confusion Matrix.....	24
3.4.3 Sensitivity.....	24

3.4.4	<i>Specificity</i>	25
3.4.5	<i>Σύγκριση</i>	25
4	Ανάπτυξη εφαρμογής	27
4.1	Εργαλεία & Βιβλιοθήκες	27
4.1.1	<i>Android Studio</i>	27
4.1.2	<i>Python Flask</i>	27
4.1.3	<i>Retrofit 2</i>	28
4.1.4	<i>HTTP POST requests</i>	28
4.1.5	<i>Ngrok</i>	28
4.2	Μοντέλο Μηχανικής Μάθησης.....	28
4.2.1	<i>Μοντέλο</i>	29
4.2.2	<i>Dataset</i>	30
4.2.3	<i>Απόδοση</i>	31
4.3	Ανάπτυξη Εφαρμογής Android.....	32
4.3.1	<i>Ενσωμάτωση Μηχανικής Μάθησης στην Εφαρμογή</i>	32
4.3.2	<i>Σύνδεση Μοντέλου και Εφαρμογής</i>	32
4.3.3	<i>Ανάπτυξη εφαρμογής</i>	33
5	Αποτελέσματα	34
5.1	Εφαρμογή	34
5.2	Τρόπος Χρήσης.....	34
5.3	Διάγραμμα Χρήσης	37
6	Συμπεράσματα - Επίλογος	39
6.1	Συμπεράσματα	39
6.2	Μελλοντικές Επεκτάσεις	39
7	Βιβλιογραφία	40

1

Εισαγωγή

1.1 Καρκίνος του Δέρματος

Ο καρκίνος του δέρματος είναι μια κακοήθης βλάβη στο δέρμα, που αναπτύσσεται από τα κύτταρα της επιδερμίδας[1] . Ειδικότερα το ανοσοποιητικό σύστημα του δέρματος εξασθενεί από την ισχυρή ηλιακή ακτινοβολία, η οποία καταστρέφει τα κύτταρα του δέρματος και τροποποιεί το γενετικό τους υλικό. Το σύστημα αναδόμησης του δέρματος δεν μπορεί να εξαλείψει τις σοβαρές βλάβες των κυττάρων του, οι οποίες σχετίζονται με την έκθεση στην υπεριώδη (UV) ακτινοβολία, και μεταβιβάζει λανθασμένες πληροφορίες στα θυγατρικά κύτταρα. Αν αυτά τα κύτταρα συνεχίζουν να διαιρούνται ανεμπόδια, είναι δυνατό να μεταλλαχθούν και να εξελιχθούν μετά από χρόνια σε καρκίνο του δέρματος [2] . Υπάρχουν τρεις βασικοί τύποι καρκίνου του δέρματος:

- **βασικοκυτταρικό καρκίνωμα**, ο πιο διαδεδομένος τύπος καρκίνου δέρματος που αναπτύσσεται από τα κύτταρα της βασικής στοιβάδας της επιδερμίδας,
- **ακανθοκυτταρικό καρκίνωμα**, ο δεύτερος πιο διαδεδομένος, που προέρχεται από τα ακανθοκύτταρα της επιδερμίδας, και
- **μελάνωμα**, από τα μελανοκύτταρα του δέρματος, τα κύτταρα δηλαδή που παράγουν την μελανίνη, την χρωστική ουσία του δέρματος. Το μελάνωμα είναι η λιγότερο συχνή μορφή καρκίνου δέρματος, αλλά η πιο επικίνδυνη[1] .

1.2 Παράγοντες

Οι βασικοί παράγοντες κινδύνου για ανάπτυξη καρκίνου του δέρματος είναι οι εξής:

- Η υπερβολική έκθεση στον ήλιο, η οποία αυξάνει τον κίνδυνο εμφάνισης καρκίνου του δέρματος, ακόμη και αν το δέρμα είναι προστατευμένο με ρουχισμό ή αντιηλιακό γαλάκτωμα. Το μαύρισμα από την ηλιοθεραπεία είναι η απόκριση του δέρματος στη βλάβη από την υπερβολική ηλιακή ακτινοβολία.
- Το ανοιχτό χρώμα του δέρματος, καθώς η μικρότερη ποσότητα μελανίνης στο δέρμα παρέχει μικρότερη προστασία από τη βλαβερή ηλιακή ακτινοβολία.
- Το ιστορικό ηλιακών εγκαυμάτων, αφού κάθε ηλιακό έγκαυμα καταστρέφει τα κύτταρα του δέρματος και αυξάνει τον κίνδυνο εμφάνισης καρκίνου του δέρματος.
- Οι δερματικοί σπίλοι (ελιές) στο δέρμα, δηλαδή οι φυσιολογικές ή μη φυσιολογικές ελιές του δέρματος, που είναι μεγαλύτερου μεγέθους από το φυσιολογικό, και είναι πιο πιθανό να μετατραπούν σε καρκινωματώδεις.
- Οι προκαρκινωματώδεις βλάβες του δέρματος.
- Η έκθεση σε περιβαλλοντικούς παράγοντες κινδύνου, κυρίως χημικές ουσίες.
- Η μεγάλη ηλικία[3] .

1.3 Συμπτώματα

Τα βασικά συμπτώματα για τους τρεις τύπους καρκίνου του δέρματος που αναφέρθηκαν παραπάνω είναι οι εξής :

- ❖ Για το βασικοκυτταρικό καρκίνο:
 - Ένα οζίδιο με υφή κεριού ή μαργαριταριού στο πρόσωπο, τα αυτιά ή το λαιμό.
 - Ένας επίπεδος σπίλος στο χρώμα του δέρματος ή μία ουλώδης βλάβη καφέ χρώματος στο στήθος ή στην πλάτη.
- ❖ Για τον ακανθοκυτταρικός καρκίνο:
 - Μια ακίνητη, κόκκινη σφαιρική μάζα στο πρόσωπο, στα χείλη, στα αυτιά, στους βραχίονες ή στα χέρια.
 - Ένας επίπεδος σπίλος, με φολιδωτή, σκληρή επιφάνεια στο πρόσωπο, στα αυτιά, στο λαιμό, στους βραχίονες ή στα χέρια.
- ❖ Για το μελάνωμα:
 - Μια καφετί κηλίδα με μικρότερες κηλίδες σε οποιοδήποτε σημείο του σώματος.

- Ένας δερματικός σπίλος σε οποιοδήποτε σημείο του σώματος, που αλλάζει χρώμα, μέγεθος, υφή ή που αιμορραγεί.
- Ένας μικρός σπίλος με ασαφή όρια και κόκκινα, λευκά, μπλέ ή μπλε-μαύρα στίγματα στον κορμό ή στα άκρα του σώματος.
- Ένα γυαλιστερό, ακίνητο οζίδιο με θολωτό σχήμα σε οποιοδήποτε σημείο του σώματος.
- Σκούρου χρώματος σπίλοι στις παλάμες, στο πέλμα, στα δάχτυλα ή στους βλεννογόνους του στόματος, της μύτης, του κόλπου ή του πρωκτού [3].

1.4 Διάγνωση και Θεραπεία

Η διάγνωση του μελανώματος, ξεκινά με τον κανόνα ABCDE της εξέτασης, που βασίζεται στα ακόλουθα χαρακτηριστικά ενός σπίλου:

- Ασυμμετρία στο σχήμα (Asymmetry)
- Ακανόνιστο ή ασαφές περίγραμμα (Border)
- Ανομοιομορφία στο χρώμα (Color)
- Μεγάλη διάμετρος (Diameter)
- Μεταβολή σε σχήμα, μέγεθος ή χρώμα με την πάροδο του χρόνου (Evolving)

Ένα βασικό όπλο υψηλής τεχνολογίας στα χέρια των δερματολόγων για την έγκαιρη ανίχνευση ύποπτων σπύλων είναι η αυτοματοποιημένη ολόσωμη χαρτογράφηση. Θεωρείται η πλέον αξιόπιστη μέθοδος διάγνωσης καρκίνου του δέρματος, καθώς η αυτοματοποιημένη διαδικασία της ελαχιστοποιεί την πιθανότητα ανθρώπινου λάθους[4] . Η χαρτογράφηση αυτή ανιχνεύει όλους τους νεοεμφανιζόμενους σπύλους και εντοπίζει με ακρίβεια οποιαδήποτε μεταβολή σε υπάρχοντες σπύλους από εξέταση σε εξέταση αξιολογώντας τον βαθμό επικινδυνότητάς τους [1] .

Σε περίπτωση επιβεβαίωσης του καρκίνου, η θεραπεία μπορεί να γίνει με πολλούς τρόπους, ανάλογα με τον τύπο του καρκινώματος. Οι μέθοδοι που επιλέγονται συνήθως είναι η κρυοθεραπεία και η τοπική χημειοθεραπεία με ειδικές αλοιφές στα μικρά βασικοκυτταρικά καρκινώματα και η χειρουργική αφαίρεση για μεγάλα καρκινώματα. Ωστόσο, η θεραπεία του μελανώματος είναι η χειρουργική αφαίρεση ανεξαρτήτως μεγέθους [5] .

1.5 Πρόληψη Καρκίνου

Παρότι σήμερα ο καρκίνος του δέρματος είναι σχεδόν πάντα θεραπεύσιμος όταν διαγνωσθεί , είναι σοφότερο κανείς να προλαμβάνει τον καρκίνο παρά να τον θεραπεύει (Ιπποκράτης) . Επομένως, είναι ωφέλιμο να ακολουθούνται οι παρακάτω συμβουλές:

- Αποφυγή παρατεταμένης έκθεσης στον ήλιο, κυρίως κατά τις πρωινές και μεσημεριανές ώρες.
- Χρήση αντιηλιακού γαλακτώματος.
- Χρήση ρούχων που προστατεύουν το δέρμα.
- Ενημέρωση από τον γιατρό ή τον φαρμακοποιό για τις παρενέργειες των φαρμακευτικών σκευασμάτων που λαμβάνονται, καθώς κάποια φαρμακευτικά σκευάσματα κάνουν το δέρμα πιο ευάλωτο στην ηλιακή ακτινοβολία [3].

1.6 Εφαρμογές Έγκαιρης Διάγνωσης

Όταν η πρόληψη δεν επιτυγχάνει στο να αποτρέψει την ύπαρξη καρκίνου του δέρματος, πλέον σημαντική για τη θεραπεία του είναι η πρόωπη ανίχνευσή του[3]. Σκοπός μας είναι να συμβάλλουμε στην έγκαιρη αυτή διάγνωση μέσω μιας εφαρμογής κινητού τηλεφώνου που θα αναγνωρίζει τότε μια κοινή ελιά είναι επικίνδυνη. Μια ιδιαίτερα επιτυχημένη προσπάθεια πραγματοποιήθηκε στο πανεπιστήμιο του Michigan, στα πλαίσια της οποίας δημιουργήθηκε η εφαρμογή UMSkinCheck που προορίζεται για αυτοεξέταση και παρακολούθηση του καρκίνου του δέρματος επιτρέποντας στους χρήστες να αποθηκεύουν μια πλήρη βιβλιοθήκη φωτογραφιών σώματος, να παρακολουθούν τις βλάβες του δέρματός τους, να κατεβάζουν ενημερωτικά βίντεο και βιβλιογραφία και να εντοπίζουν ειδικούς στον τομέα του καρκίνου του δέρματος. Άτομα που διατρέχουν υψηλό κίνδυνο καρκίνου του δέρματος και χρειάζονται να κάνουν συχνούς αυτοελέγχους του δέρματος , μπορούν πλέον με την εφαρμογή αυτή να πραγματοποιούν μια πλήρη αυτοεξέταση στο σώμα τους, καθώς και να δημιουργούν και να παρακολουθούν ένα ιστορικό σπύλων και βλαβών σε μια φορητή συσκευή[6]. Εμπνευσμένοι από την ενέργεια αυτή , προχωρήσαμε στην πραγματοποίηση μιας νέας εφαρμογής για τον καρκίνο του δέρματος, η οποία θα αναλυθεί εκτενώς στη συνέχεια.

2

Προηγούμενες Έρευνες

2.1 Εμπόδια

Στην προσπάθεια έγκαιρης διάγνωσης καρκίνου του δέρματος, προκύπτει η ανάγκη για την μείωση της υποκειμενικότητας που έχει η ανθρώπινη ερμηνεία των εικόνων. Κάτι τέτοιο γίνεται εφικτό με την χρήση αυτοματοποιημένων μεθόδων για τον διαχωρισμό της αλλοίωσης από το υπόλοιπο κομμάτι. Τέτοιες μέθοδοι έχουν υπάρξει αρκετοί με διάφορα επίπεδα επιτυχίας. Στην παρούσα εργασία θα εφαρμοστούν μοντέλα μηχανικής μάθησης για να επιτευχθεί αυτό. Η αυτοματοποίηση της διαδικασίας διαχωρισμού της αλλοίωσης από την υπόλοιπη περιοχή είναι εξαιρετικά σημαντική για την περαιτέρω ανάλυση της εικόνας για πολλούς λόγους. Αρχικά τα όρια της αλλοίωσης προσδίδουν σημαντική πληροφορία για την διάγνωση, αφού πολλά χαρακτηριστικά όπως η ασυμμετρία και το απότομο απόκομμά της υπολογίζονται απευθείας από την περιοχή των ορίων. Έπειτα η εξαγωγή αρκετών κλινικών χαρακτηριστικών που δεν φαίνεται να σχετίζονται άμεσα με την περιοχή των ορίων έχουν έμμεση συσχέτιση με αυτή ή καλύτερα την ακρίβεια με την οποία έχει υπολογιστεί. Δυστυχώς βέβαια, η αυτοματοποίηση της διαδικασίας βρίσκει αρκετά εμπόδια. Χαμηλή αντίθεση στο χρώμα της αλλοίωσης, αρκετά περίπλοκα όρια, τρίχες και αιμοφόρα αγγεία είναι κάποια από αυτά που καλείται ένας αλγόριθμος κατάτμησης της εικόνας να υπερβεί. Ο σκοπός μας στην παρούσα εργασία είναι ο διαχωρισμός των σπύλων που παρουσιάζουν κακοήθεια από τις υπόλοιπες.

2.2 Προσεγγίσεις

Η ταξινόμηση των εικόνων δερματικής βλάβης είναι ένα κεντρικό θέμα στην ιατρική απεικόνιση, έχοντας σχετικά εκτεταμένη βιβλιογραφία. Ορισμένες από τις πρώτες μεθόδους για την ταξινόμηση δερματικών αλλοιώσεων έχουν επικεντρωθεί κυρίως σε προσεγγίσεις χαμηλού επιπέδου υπολογιστικής όρασης, οι οποίες περιλαμβάνουν χειροκίνητα χαρακτηριστικά βασισμένα σε ειδικές γνώσεις όπως το χρώμα, το σχήμα και την υφή. Αξιοποιώντας την επιλογή χαρακτηριστικών, οι προσεγγίσεις που χρησιμοποιούν τεχνικές όρασης υπολογιστή μεσαίου επιπέδου έχουν επίσης αποδειχθεί ότι επιτυγχάνουν βελτιωμένη απόδοση ανίχνευσης [7]. Εκτός από τις τεχνικές που βασίζονται στην ταξινόμηση συνόλου [8], άλλες μέθοδοι περιλαμβάνουν προσεγγίσεις δύο σταδίων, οι οποίες συνήθως περιλαμβάνουν τμηματοποίηση των βλαβών του δέρματος, ακολουθούμενη από ένα στάδιο ταξινόμησης για περαιτέρω βελτίωση της απόδοσης ανίχνευσης. Ωστόσο, τα χειροποίητα χαρακτηριστικά συχνά οδηγούν σε μη ικανοποιητικά αποτελέσματα σε αόρατα δεδομένα λόγω της μεγάλης διακύμανσης εντός της κατηγορίας και της οπτικής ομοιότητας, καθώς και της παρουσίας αντικειμένων σε δερματοσκοπικές εικόνες. Επιπλέον, τέτοιες δυνατότητες είναι συνήθως σχεδιασμένες για συγκεκριμένες εργασίες και δεν γενικεύονται. Η βαθιά μάθηση φάνηκε πρόσφατα ως ένας πολύ ισχυρός τρόπος για την εύρεση μοτίβων χρησιμοποιώντας μεγάλες ποσότητες εκπαιδευτικών δεδομένων.

Η βαθιά μάθηση έχει αποδειχθεί πολύτιμη για διάφορες ιατρικές εργασίες ανάλυσης εικόνας όπως η ταξινόμηση και κατάτμηση. Συγκεκριμένα, υπήρξαν σημαντικά κέρδη απόδοσης στην αναγνώριση μελανώματος που επιτυγχάνεται με την αξιοποίηση των βαθιών συνελκτικών νευρωνικών δικτύων.

2.3 Μοντέλα

Ωστόσο, τα ζητήματα της χαμηλής διακύμανσης μεταξύ των τάξεων και της ανισορροπίας τάξης των συνόλων δεδομένων εικόνων του δέρματος υπονομεύουν σοβαρά τις εφαρμογές της βαθιάς μάθησης για την ανίχνευση μελανώματος [9], καθώς συχνά εμποδίζουν την ικανότητα γενίκευσης του μοντέλου, οδηγώντας σε overfitting [10].

Πρόσφατα αναπτύχθηκαν πολλές εργασίες ιατρικής απεικόνισης, συμπεριλαμβανομένης της ανίχνευσης καρκίνου του δέρματος. Προσεγγίσεις που καθιστούν δυνατή την εκπαίδευση διαφορετικών μοντέλων με βάση την αντιστοίχιση διανομής με δεδομένα σε ζεύγη αλλά και χωρίς ζεύγη εισήχθησαν στα papers [11],[12],[13]. Αυτές οι προσεγγίσεις περιλαμβάνουν

μετάφραση εικόνας από CT-PET [14], CS-MRI [15], MR-CT [16], XCAT-CT [17] και χρώση H&E στην ιστοπαθολογία [18], [19]. Στα [20][21], αναπτύχθηκαν μοντέλα σύνθεσης εικόνων που συνθέτουν εικόνες από θόρυβο, σε μια προσπάθεια βελτίωσης της ανίχνευσης μελανώματος. Ωστόσο, αποδείχτηκε (Cohen et al. [22]) ότι τα προγράμματα κατάρτισης που χρησιμοποιούνται σε διάφορες μεθόδους προσαρμογής, συχνά οδηγούν σε υψηλές «προκαταλήψεις» (bias) και μπορεί να οδηγήσουν σε μη πραγματικά χαρακτηριστικά (π.χ. προσθήκη ή αφαίρεση όγκων που οδηγούν σε σημασιολογική αλλαγή). Αυτό οφείλεται σε μεγάλο βαθμό στους τομείς προέλευσης ή προορισμού, που αποτελούνται από δείγματα που υπερ-ή-ύπο-εκπροσωπούνται κατά τη διάρκεια της εκπαίδευσης (π.χ. τομέας προέλευσης που αποτελείται από 50% κακοήθεις εικόνες και 50% καλοήθεις ή τομέας προορισμού που αποτελείται από 20% κακοήθεις και 80% καλοήθεις εικόνες).

Πιο συγκεκριμένα, παρόμοια έρευνα με την παρούσα εργασία, αποτελεί το έργο των Lopez κ.α., [23], οι οποίοι ασχολήθηκαν με το πρόβλημα της ταξινόμησης των δερματικών βλαβών, ιδιαίτερα της πρώιμης ανίχνευσης μελανώματος, παρουσιάζοντας μια προσέγγιση βασισμένη στη βαθιά μάθηση για την επίλυση του προβλήματος της ταξινόμησης μιας δερματοσκοπικής εικόνας που περιέχει μια δερματική βλάβη, ως κακοήθη ή καλοήθη. Η προτεινόμενη λύση βασίζεται στην αρχιτεκτονική του συνελκτικού νευρωνικού δικτύου VGGNet και χρησιμοποιεί το πρότυπο του transfer learning και του fine-tuning της αρχιτεκτονικής του CNN (Convolutional Neural Network). Σύμφωνα με τα αποτελέσματα, στο σύνολο δεδομένων του αρχείου ISIC, η προτεινόμενη μέθοδος επιτυγχάνει μια τιμή ευαισθησίας 78,66% [23].

Ένα σημαντικό βήμα στην ηλεκτρονική αξιολόγηση των βλαβών του δέρματος είναι η ακριβής ανίχνευση της περιοχής της βλάβης, δηλαδή η τμηματοποίηση μιας εικόνας σε δύο περιοχές ως βλάβη και κανονικό δέρμα. Με γνώμονα το παραπάνω, μια ομάδα ατόμων πραγματοποίησε πειράματα σε εικόνες που ενδέχεται να έχουν φωτισμό και θόρυβο, μέσω μιας μεθόδου βασισμένης σε βαθιά νευρωνικά δίκτυα, με σκοπό την ακριβή εξαγωγή μιας περιοχής βλάβης. Οι εικόνες τροφοδοτούνται σε ένα δίκτυο CNN 5 επιπέδων μετά την αφαίρεση των αντικειμένων θορύβου και φωτισμού. Η ευαισθησία (Sensitivity) του μοντέλου είναι 0.81 ενώ η ειδικότητα (Specificity) ισούται με 0.8. Η έρευνα δημοσιεύτηκε από το Institute of Electrical and Electronics Engineers Inc [24].

Με τον ίδιο παραπάνω στόχο, οι Yu κ.α. προτείνουν ένα σύστημα που συνδυάζει τις πρόσφατες εξελίξεις του deep learning με καθιερωμένες προσεγγίσεις μηχανικής μάθησης, δημιουργώντας σύνολα μεθόδων που μπορούν να τμηματοποιήσουν τις δερματικές βλάβες, καθώς και να αναλύσουν την ανιχνευμένη περιοχή και τον περιβάλλοντα ιστό για ανίχνευση μελανώματος. Το αποτέλεσμα του πειράματος δείχνει ότι η τμηματοποίηση αποδίδει καλύτερα, καθώς η τμηματοποίηση επιτρέπει στη διαδικασία εξαγωγής χαρακτηριστικών να διεξάγεται μόνο στις περιοχές βλάβης και έτσι δημιουργούνται πιο συγκεκριμένα και αντιπροσωπευτικά χαρακτηριστικά[25] .

Τέλος , οι Codella κ.α. χρησιμοποιούν τεχνικές εξαγωγής χαρακτηριστικών με κωδικοποίηση χειρός, όπως ιστόγραμμα χρώματος, ιστόγραμμα άκρης και μια παραλλαγή πολλαπλών κλιμάκων τοπικών δυαδικών χρωμάτων (LBP). Ειδικότερα εκτελούν ταξινόμηση των περιπτώσεων μελανώματος έναντι μη μελανώματος και επίσης μελάνωμα έναντι άτυπων βλαβών μόνο. Η μέθοδος επιτυγχάνει ακρίβεια 93,1% για την πρώτη εργασία και 73,9% για τη δεύτερη. Παρατηρείται ότι η διάκριση μελανώματος από άτυπες περιπτώσεις είναι πιο δύσκολη. Αυτή η μέθοδος ακολουθεί δύο παράλληλες διαδρομές: (1) CNN με μεταφορά μάθησης από φυσικό σύνολο δεδομένων. (2) Μη επιβλεπόμενη μάθηση χαρακτηριστικών με αραιή κωδικοποίηση. Οι ταξινομητές στη συνέχεια εκπαιδεύονται σε καθένα χρησιμοποιώντας μη γραμμικό SVM, χρησιμοποιώντας HIK (πυρήνας διασταύρωσης ιστογράμματος) και ομαλοποίηση χαρακτηριστικού σιγμοειδούς, ενώ στη συνέχεια το μοντέλο συνδυάζεται σε καθυστερημένη σύντηξη (μέσος όρος βαθμολογίας) [26] .

Τα αποτελέσματα των παραπάνω φαίνονται συνοπτικά στον παρακάτω πίνακα :

Methods	Dataset	ACC	SE	SP	PREC	ACC
Fine-tuning using VGGNet	ISBI 2016	0.813	0.7866	-	0.7974	-
Fully convolutional residual network + deep residual network	ISBI 2016	0.855	0.5407	0.941	0.637	0.804
5 layer CNN	MED-NODE	0.81	0.81	0.80	-	-
Deep learning ensemble	ISIC	0.807	0.693	0.836	0.649	0.843

Επιπλέον, μια άλλη μελέτη προβάλλει ένα μοντέλο ταξινόμησης το οποίο με βάση την τμηματοποίηση για τη διάγνωση βλάβης του δέρματος συνδυάζει έναν αλγόριθμο GrabCut και ένα μοντέλο Adaptive Neuro-Fuzzy classifier (ANFC). Η προτεινόμενη μέθοδος περιλαμβάνει τέσσερα κύρια βήματα: προεπεξεργασία, τμηματοποίηση, εξαγωγή χαρακτηριστικών και ταξινόμηση. Αρχικά, το στάδιο προεπεξεργασίας πραγματοποιείται χρησιμοποιώντας φίλτρο Top Hat και τεχνική βαφής. Στη συνέχεια, ο αλγόριθμος Grabcut χρησιμοποιείται για την τμηματοποίηση των προεπεξεργασμένων εικόνων. Στη συνέχεια, η διαδικασία εξαγωγής χαρακτηριστικών πραγματοποιείται με τη χρήση ενός μοντέλου Inception βασισμένο σε βαθιά μάθηση. Τέλος, ένα προσαρμοστικό σύστημα νευρο-ασαφούς ταξινομητή (ANFC) εκτελείται για να ταξινομήσει τις δερματοσκοπικές εικόνες σε διαφορετικές κατηγορίες. Το προτεινόμενο μοντέλο προσομοιώνεται χρησιμοποιώντας ένα σύνολο δεδομένων International Skin Imaging Collaboration (ISIC) και τα αποτελέσματα εξετάζονται ως προς την ακρίβεια, την ευαισθησία και την ειδικότητα. Οι πειραματικές τιμές έδειξαν ότι η προτεινόμενη μέθοδος προσέφερε μέγιστη ευαισθησία 93,40%, ειδικότητα 98,70% και ακρίβεια 97,91% [27].

Το άρθρο [28] ομοίως με τα προηγούμενα ασχολείται με ένα γρήγορο και αποδοτικό σύστημα ταξινόμησης του καρκίνου του δέρματος χρησιμοποιώντας σύγχρονο, βαθύ συνελικτικό νευρικό δίκτυο. Η εστίαση γίνεται κυρίως στο έργο της ταξινόμησης του καρκίνου του δέρματος χρησιμοποιώντας το ECOC SVM και το βαθύ συνελικτικό νευρωνικό δίκτυο. Εικόνες RGB των καρκίνων του δέρματος συλλέγονται από το Διαδίκτυο, ενώ όσες συλλεγόμενες εικόνες έχουν θορύβους, περικόπτονται για καλύτερα αποτελέσματα. Ένα υπάρχον και προ-εκπαιδευμένο μοντέλο συνελικτικού νευρωνικού δικτύου AlexNet χρησιμοποιείται για την εξαγωγή χαρακτηριστικών και ένας διαχωριστής ECOC SVM χρησιμοποιείται για την ταξινόμηση του καρκίνου του δέρματος. Τα αποτελέσματα λαμβάνονται εκτελώντας έναν προτεινόμενο αλγόριθμο με συνολικά 3753 εικόνες, οι οποίες περιλαμβάνουν τέσσερα είδη εικόνων για καρκίνο του δέρματος. Το αποτέλεσμα εφαρμογής δείχνει ότι οι μέγιστες τιμές της μέσης ακρίβειας, ευαισθησίας και ειδικότητας είναι 95,1 (καρκίνωμα πλακωδών κυττάρων), 98,9 (ακτινική κερατίωση), 94,17 (καρκίνωμα πλακωδών κυττάρων), αντίστοιχα.

Στο άρθρο [29] προτείνεται μια αυτοματοποιημένη μέθοδος ταξινόμησης βλάβης του δέρματος. Σε αυτήν τη μέθοδο, χρησιμοποιείται ένα εκπαιδευμένο δίκτυο βαθιάς μάθησης και η εκμάθηση μεταφοράς. Εκτός από την τελειοποίηση και την αύξηση των δεδομένων, η εκμάθηση μεταφοράς εφαρμόζεται στο AlexNet αντικαθιστώντας το τελευταίο στρώμα από ένα softmax για την ταξινόμηση τριών διαφορετικών βλαβών (μελάνωμα, κοινός σπίλος και άτυπος σπίλος). Το προτεινόμενο μοντέλο εκπαιδεύεται και δοκιμάζεται χρησιμοποιώντας το σύνολο δεδομένων PH_2 [30]. Τα γνωστά ποσοτικά μέτρα, η ακρίβεια, η ευαισθησία, η ειδικότητα και η ακρίβεια χρησιμοποιούνται για την αξιολόγηση της απόδοσης της προτεινόμενης μεθόδου όπου οι ληφθείσες τιμές αυτών των μέτρων είναι 98,61%, 98,33%, 98,93% και 97,73%, αντίστοιχα.

3

Μοντέλο Μηχανικής Μάθησης

Επιχειρήσαμε να εκπαιδεύσουμε ένα μοντέλο μηχανικής μάθησης για την ανίχνευση καρκίνου του δέρματος μέσω εικόνας. Παρακάτω παρουσιάζεται η πειραματική διαδικασία που ακολουθήθηκε, καθώς και τα αποτελέσματα που λάβαμε.

3.1 Βασικές έννοιες

3.1.1 Μηχανική Μάθηση

Η μηχανική μάθηση μπορεί να θεωρηθεί ως "η αναζήτηση σε ένα χώρο πιθανών υποθέσεων, εκείνης της υπόθεσης που ταιριάζει κατά τον καλύτερο τρόπο στα υπό εξέταση δεδομένα και στην πιθανώς προϋπάρχουσα γνώση". Αποτελεί παρακλάδι της τεχνητής νοημοσύνης.


3.1.2 Transfer Learning

Στις παραδοσιακές προσεγγίσεις της Μηχανικής Μάθησης, κάθε μοντέλο κατασκευάζεται έτσι ώστε να αντιμετωπίζει ένα συγκεκριμένο σετ δεδομένων. Αυτό έχει ως αποτέλεσμα να μην εκμεταλλεύεται η πληροφορία όλων των προηγούμενων μοντέλων που έχουν εκπαιδευτεί αλλά και να στηρίζεται η εκπαίδευση των νέων μοντέλων σε πολλούς πόρους και στην εύρεση επαρκούς πλήθους νέων δεδομένων. Η μεταφορά μάθησης (transfer learning) είναι η τεχνική κατά την οποία εκπαιδεύονται μοντέλα με ένα μεγάλο σετ δεδομένων και ύστερα αυτά τα εκπαιδευμένα μοντέλα αξιοποιούνται σε διαφορετικά αλλά παρεμφερή δεδομένα. Όταν ένα μοντέλο εκπαιδεύεται πάνω σε ένα σετ δεδομένων, προσπαθεί να εξάγει πληροφορίες για την κατανομή του. Όλη αυτή η πληροφορία που λαμβάνει, λοιπόν, είναι χρήσιμη και δεν πρέπει να αγνοηθεί, καθώς μπορεί να αξιοποιηθεί άμεσα χωρίς εκ νέου εκπαίδευση σε ένα νέο σετ δεδομένων. Σε περιπτώσεις που διατίθενται λίγοι πόροι ή ελάχιστα δεδομένα η τεχνική της

μεταφοράς μάθησης μπορεί να δώσει εξαιρετικά αποτελέσματα. Η έννοια αυτή εισήχθη πρώτη φορά στο συνέδριο NIPS το 1995 στην ημερίδα "Learning to Learn: Knowledge Consolidation and Transfer in Inductive Systems" [31] και άρχισε να εξελίσσεται ιδιαίτερα την τελευταία δεκαετία. Η μεταφορά μάθησης λειτουργεί, λοιπόν, μέσω της επαναχρησιμοποίησης ενός προ-εκπαιδευμένου μοντέλου σε ένα νέο πρόβλημα. Αυτή τη στιγμή είναι πολύ δημοφιλής στη βαθιά μάθηση, γιατί μπορεί να εκπαιδεύσει βαθιά νευρωνικά δίκτυα με σχετικά λίγα δεδομένα[32].

Ουσιαστικά προσπαθούμε να εκμεταλλευτούμε οτιδήποτε έχει μάθει το μοντέλο σε μια εργασία για να βελτιώσουμε τη γενίκευση σε ένα άλλο. Μεταφέρουμε τα βάρη που έχει μάθει ένα δίκτυο στο "task A" σε ένα νέο "task B." Η γενική ιδέα είναι να χρησιμοποιήσουμε τις γνώσεις που ένα μοντέλο έχει μάθει από μια εργασία με πολλά διαθέσιμα δεδομένα εκπαίδευσης με ετικέτες, σε μια νέα εργασία που δεν έχει πολλά δεδομένα. Αντί να ξεκινήσουμε τη μαθησιακή διαδικασία από το μηδέν, ξεκινάμε με μοτίβα που μαθαίνουμε από την επίλυση μιας σχετικής εργασίας.

Η αιτία καθιέρωσης του transfer learning είναι το γεγονός ότι τα state-of-the-art μοντέλα αποτελούνται από πάρα πολλές παραμέτρους με αποτέλεσμα να απαιτούνται εξίσου πολλά δείγματα-εικόνες για την εκπαίδευσή τους. Στην πράξη, η εύρεση ενός ικανοποιητικού αριθμού δεδομένων δεν είναι εύκολη υπόθεση και έτσι οδηγούμαστε στην χρήση μοντέλων προεκπαιδευμένων σε ένα πολύ μεγάλο σύνολο δεδομένων (π.χ. ImageNet) ως βάση για την επίλυση του προβλήματος μας. Επιπλέον επιλέγουμε τη μεταφορά μάθησης, για να εξοικονομήσουμε χρόνο εκπαίδευσης, για να επιτύχουμε μια καλύτερη απόδοση νευρωνικών δικτύων (τις περισσότερες φορές) και να μη χρειαστούμε ιδιαίτερα πολλά δεδομένα. Αξίζει να σημειωθεί ότι ο χρόνος εκπαίδευσης για την εκπαίδευση βαθιών νευρωνικών δικτύων from scratch μπορεί να είναι μέρες ή και εβδομάδες σε ένα περίπλοκο task[33].



Οφέλη της μεθόδου Transfer Learning

3.2 Εργαλεία

3.2.1 Google Colaboratory

Το πείραμά μας ως προς τη μηχανική μάθηση υλοποιήθηκε εξ ολοκλήρου στο Google Colaboratory, εν συντομία Google Colab. Πρόκειται για ένα cloud-based Jupyter notebook περιβάλλον που επιτρέπει την ανάπτυξη και την εκτέλεση κώδικα Python εντός του browser. [34] Επιπλέον, μέσω του Google Drive, δίνεται η δυνατότητα εισαγωγής εξωτερικών δεδομένων για την υλοποίηση εφαρμογών μηχανικής μάθησης (machine learning), ανάλυσης δεδομένων (data analysis) κ.ά.. Το γεγονός ότι ο κώδικας των notebooks εκτελείται στους servers της Google δίνει την δυνατότητα στον χρήστη να εργαστεί με GPUs.

3.2.2 Keras

Για την υλοποίηση του νευρωνικού μας δικτύου χρησιμοποιήθηκε η διεπαφή προγραμματιστικών εφαρμογών (API) Keras. Το Keras είναι API ανοιχτού κώδικα, γραμμένο στη γλώσσα προγραμματισμού Python. Δεν αποτελεί αυτόνομη βιβλιοθήκη αλλά high-level διεπαφή η οποία τρέχει πάνω από low-level βιβλιοθήκες (TensorFlow, Theano, Microsoft Cognitive Toolkit). Το Keras σχεδιάστηκε ώστε να επιταχύνει και να διευκολύνει την ανάπτυξη βαθιών νευρωνικών δικτύων (deep neural networks). Παράλληλα, εστιάζει στο να είναι φιλική προς το χρήστη (user friendly), αρθρωτή (modular) και επεκτάσιμη (extensible) [35].

3.3 Ανάλυση του μοντέλου

Το πρόβλημά μας πρόκειται για ένα binary classification πρόβλημα. Ουσιαστικά χρειάστηκε να δημιουργήσουμε έναν binary image classifier. Αυτό είναι ένα από τα πιο συχνά χρησιμοποιούμενα προβλήματα στη μηχανική μάθηση. Στην απλούστερη μορφή, ο χρήστης προσπαθεί να ταξινομήσει μια εικόνα σε μία από τις δύο πιθανές κατηγορίες. Στην περίπτωσή μας, κατηγοριοποιήσαμε τις εικόνες σε δύο κατηγορίες, Malignant (καρκίνος) και Benign (όχι καρκίνος).

3.3.1 Dataset και επεξεργασία δεδομένων

Επανεκπαιδεύσαμε το μοντέλο μας με μεταφορά μάθησης χρησιμοποιώντας το σύνολο δεδομένων που μας δόθηκε με επεξεργασμένες εικόνες καρκίνου του δέρματος του αρχείου ISIC.¹ Τα δεδομένα αποτελούνται από δύο φακέλους ο καθένας με 1800 εικόνες (224x224) των δύο τύπων, καλοηθών και κακοήθων, δερματικών σπύλων.

Αρχικά, αφού εισαγάγαμε τις απαραίτητες βιβλιοθήκες, αποθηκεύσαμε το σύνολο δεδομένων εικόνων σε μεταβλητές, έχοντας ήδη μεταφέρει το dataset των εικόνων στον αποθηκευτικό χώρο του Google Drive μας. Δημιουργήσαμε μια συνάρτηση για τη φόρτωση φακέλων που περιέχουν εικόνες σε πίνακες, καθορίζοντας ταυτόχρονα ένα μέγεθος βάσης για όλες τις εικόνες που τροφοδοτούνται στους αλγόριθμους ΑΙ.

Αφού ορίσαμε τις ετικέτες για το train set και το test set ως benign ή malignant αντίστοιχα, κάναμε shuffle στα δεδομένα μας για να ορίσουμε το validation set μας. Για λόγους απλότητας αλλά και συμβατότητας με κάποια από το μοντέλο που χρησιμοποιήσαμε όλες οι εικόνες αναδιαμορφώθηκαν στα 224x224 pixels. Αυτό σαφώς σημαίνει πως έχουμε μια λίγο χειρότερη ανάλυση των αρχικών εικόνων, όμως είναι ένας περιορισμός που πρέπει να ληφθεί δεδομένου των διαθέσιμων πόρων.

Στη συνέχεια κανονικοποιήσαμε τα δεδομένα μας και χρησιμοποιήσαμε επαύξηση δεδομένων. Η επαύξηση δεδομένων επιτρέπει να δημιουργήσουμε μεγαλύτερη ποικιλία στα δεδομένα εφαρμόζοντας τυχαίους αλλά ρεαλιστικούς μετασχηματισμούς στις εικόνες, όπως πχ η περιστροφή. Προσθέσαμε σχόλια στον κώδικά μας για κάθε επεξεργασία που εφαρμόστηκε κατά τη διαδικασία αυτή.

3.3.2 Επιλογή αρχιτεκτονικής δικτύου

Κληθήκαμε να επιλέξουμε ανάμεσα σε διάφορα μοντέλα από τα οποία εν τέλει καταλήξαμε στο EfficientNet-B0. Μερικές από τις επικρατέστερες επιλογές ήταν τα εξής μοντέλα: ConvNet, VGG16 και ResNet50.

¹ <https://www.kaggle.com/fanconic/skin-cancer-malignant-vs-benign>

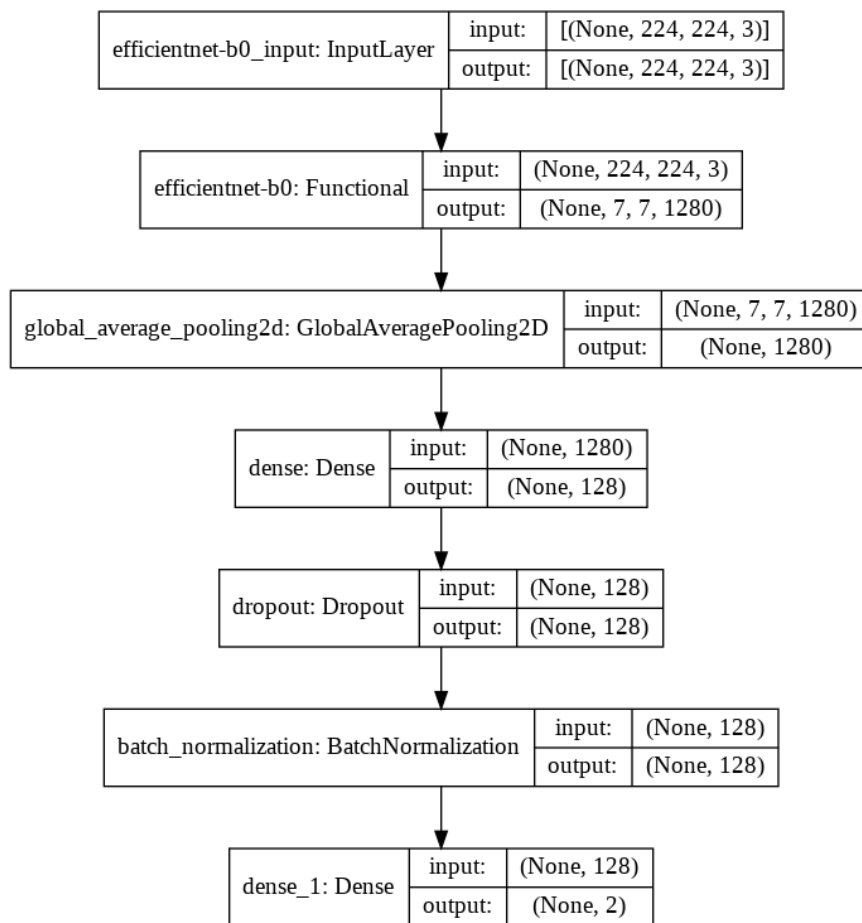
3.3.3 *EfficientNet-B0*

Το Μάιο του 2019, οι μηχανικοί Mingxing Tan και Quoc V. Le της Google Brain Team, δημοσίευσαν το άρθρο “EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks”[36]. Βασικός στόχος της δημοσίευσης ήταν η εισαγωγή μιας αποτελεσματικής στρατηγικής κλιμάκωσης νευρωνικών δικτύων, παράλληλα όμως εισήγαγαν μία νέα οικογένεια νευρωνικών δικτύων, τα EfficientNets.

Η αρχιτεκτονική EfficientNet-B0 αποτελεί το μοντέλο-βάση για την ανάπτυξη των υπολοίπων EfficientNets. Σχεδιάστηκε μέσω της τεχνικής “Neural Architecture Search” (NAS). Η NAS αυτοματοποιεί το σχεδιασμό νευρωνικών δικτύων με στόχο την βελτιστοποίηση της απόδοσης τους και την ελαχιστοποίηση της πολυπλοκότητας τους. Η αρχιτεκτονική που προέκυψε περιέχει έντεκα εκατομμύρια παραμέτρους προς εκπαίδευση και έχει ως δομικά στοιχεία τη συνάρτηση ενεργοποίησης Swiss, τα Inverted Residual Blocks και τα Squeeze & Excitation Blocks[37]. Η αρχιτεκτονική του EfficientNet-B0 αρχικά διαθέτει ένα συνελκτικό επίπεδο και στη συνέχεια επτά Inverted Residual Blocks. Κάθε ένα από αυτά τα Blocks διαθέτει διαφορετικά χαρακτηριστικά. Μετά τα Blocks ακολουθεί ένα συνελκτικό επίπεδο, ένα επίπεδο συγκέντρωσης και τέλος ένα πλήρως συνδεδεμένο επίπεδο.

Καταλήξαμε στο συμπέρασμα ότι το μοντέλο αυτό είναι το βέλτιστο για το πρόβλημά μας, αφού μελετήσαμε και συμβουλευτήκαμε αντίστοιχες έρευνες και papers σε προβλήματα σχετικά με την αναγνώριση καρκίνου του δέρματος μέσω εικόνων, εστιασμένες στη μηχανική μάθηση, που δοκίμασαν όλα τα παραπάνω μοντέλα με διάφορες παραμέτρους. Το αμέσως επόμενο φαίνεται να ήταν το ResNet50.

Αφού ορίσαμε το ακολουθιακό μοντέλο μας, καταλήξαμε στην εξής αρχιτεκτονική:



Εκπαιδεύσαμε το μοντέλο μας χρησιμοποιώντας τον βελτιστοποιητή Adam Optimizer, ξεκινώντας από learning rate 0.001, για 100 εποχές. Ουσιαστικά αν το accuracy του μοντέλου μας δεν βελτιωνόταν μετά από 3 εποχές, το learning rate μειωνόταν κατά 0.5. Αυτό το πετύχαμε χρησιμοποιώντας την κλάση ReduceLROnPlateau.

3.3.4 Adam Optimizer

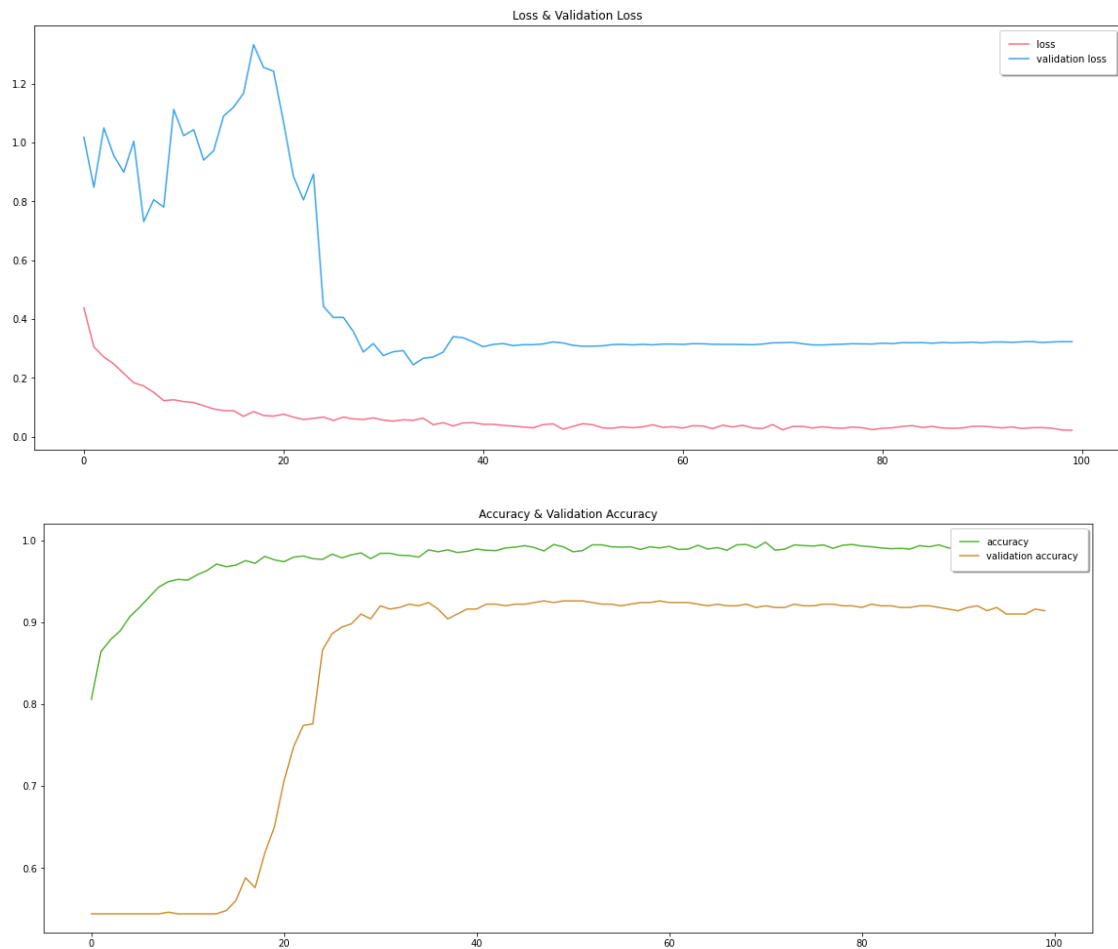
Η επιλογή του βελτιστοποιητή Adam optimizer έγινε διότι πρόκειται για έναν βελτιστοποιητή εύκολο στην εφαρμογή, αρκετά αποτελεσματικό υπολογιστικά, ο οποίος απαιτεί μικρό χώρο, είναι καλός για μη σταθερούς στόχους, λειτουργεί καλά σε προβλήματα με θορυβώδεις ή αραιές κλίσεις και λειτουργεί καλά με μεγάλα σύνολα δεδομένων και μεγάλες παραμέτρους. Ωστόσο ως βελτιστοποιητής τείνει να συγκλίνει γρηγορότερα από άλλους, αλλά αλγόριθμοι όπως ο Stochastic gradient descent εστιάζουν στα σημεία δεδομένων και έτσι έχουμε καλύτερη γενίκευση [38]. Ο Adam σχεδιάστηκε για να συνδυάζει τα πλεονεκτήματα του Adagrad, ο οποίος λειτουργεί καλά με αραιές κλίσεις και του RMSprop, ο οποίος λειτουργεί καλά σε online ρυθμίσεις. Συνδυάζοντας αυτά τα δύο χαρακτηριστικά, καταφέρνουμε να

χρησιμοποιήσουμε τον Adam για ένα ευρύτερο φάσμα εργασιών. Ο Adam μπορεί επίσης να θεωρηθεί ως ο συνδυασμός των RMSprop και SGD, οπότε θεωρήθηκε η βέλτιστη επιλογή για την δική μας περίπτωση.

3.4 Αποτελέσματα

Επιλέξαμε να αναπαραστήσουμε τα αποτελέσματά μας με διαγράμματα.

3.4.1 Loss - Accuracy



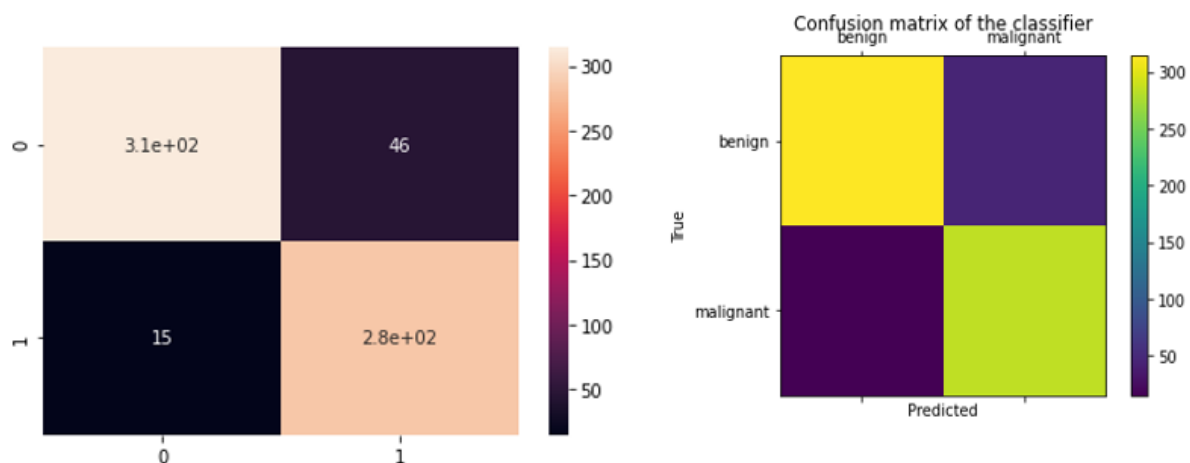
Παρατηρούμε ότι μετά τις 40-50 εποχές το μοντέλο μας σταματάει να βελτιώνεται, ίσως λόγω εξαιρετικά μειωμένου learning rate ή χρήσης λίγων παραμέτρων. Ωστόσο τα αποτελέσματα είναι ικανοποιητικά.

3.4.2 Confusion Matrix

Η βάση για τις μετρικές απόδοσης των ταξινομητών είναι ο πίνακας σύγχυσης (confusion matrix). Ο πίνακας σύγχυσης C είναι τέτοιος ώστε το $C_{i,j}$ είναι ίσο με τα δείγματα που ενώ ανήκουν στην κατηγορία i ταξινομήθηκαν στην κατηγορία j . Στη δική μας περίπτωση, ο πίνακας σύγχυσης ήταν ο εξής:

```
[[314  46]
 [ 15 285]]
```

Τα στοιχεία της διαγωνίου είναι αληθινά θετικά δείγματα (true positive) της κάθε κλάσης. Για κάθε κλάση i τα στοιχεία της γραμμής i εκτός της διαγωνίου είναι λανθασμένα αρνητικά δείγματα (false negative) της κλάσης και τα στοιχεία της στήλης i εκτός της διαγωνίου είναι λανθασμένα θετικά δείγματα (false positive) της κλάσης. Στη δική μας περίπτωση έχουμε μόνο 15 false negative δείγματα, δηλαδή δείγματα ασθενών που ταξινομήθηκαν ως υγιή και 46 δείγματα που ταξινομήθηκαν ως ασθενή ενώ ήταν υγιή (false positive).



3.4.3 Sensitivity

Η ευαισθησία (Sensitivity) δείχνει ποιο ποσοστό της θετικής τάξης, δηλαδή των πραγματικών ασθενών, ταξινομήθηκε σωστά, δηλαδή ανιχνεύθηκαν σωστά από το μοντέλο.

$$Sensitivity = \frac{TP}{TP + FN}$$

Όσο μεγαλύτερο είναι το ποσοστό ευαισθησίας, τόσο καλύτερο είναι το μοντέλο.

FN – False Negatives είναι ο αριθμός των δειγμάτων θετικής τάξης (ασθενών) που ταξινομήθηκαν λανθασμένα ως υγιείς από το μοντέλο. Επιθυμούμε, όπως είναι λογικό, ο αριθμός αυτός να είναι ο ελάχιστος δυνατός.

Στην περίπτωση μας, $Sensitivity = \frac{285}{285+15} = 0.95$ ή 95%, το οποίο είναι ένα πολύ υψηλό ποσοστό.

3.4.4 Specificity

Specificity (ειδικότητα) ορίζεται η αναλογία των πραγματικών αρνητικών δειγμάτων, στην περίπτωση μας υγιών, τα οποία προβλέπονται όντως ως αρνητικά (true negative). Αυτό σημαίνει ότι θα υπάρξει ένα άλλο ποσοστό των πραγματικών αρνητικών, το οποίο είχε προβλεφθεί ως θετικό και θα μπορούσε να χαρακτηριστεί ως ψευδώς θετικό. Αυτό το ποσοστό θα μπορούσε επίσης να ονομαστεί ψευδώς θετικό ποσοστό. Το άθροισμα της ειδικότητας και του ψευδούς θετικού ποσοστού θα είναι πάντα 1. Η ειδικότητα είναι ένα μέτρο του ποσοστού των ατόμων που δεν πάσχουν από καρκίνο του δέρματος και έχουν προβλεφθεί σωστά ως υγιή.

$$Specificity = \frac{TN}{TN + FP}$$

Στο δικό μας μοντέλο, $Specificity = \frac{314}{314+46} = 0.87$ ή 87% , το οποίο είναι επίσης ένα πολύ υψηλό ποσοστό.

3.4.5 Σύγκριση

Συγκριτικά με τα μοντέλα που αναλύσαμε στο κεφάλαιο 2, παρατηρούμε ότι το μοντέλο μας φαίνεται να δίνει πάρα πολύ καλό ποσοστό ευαισθησίας και ειδικότητας, μετρικές που είναι οι σημαντικότερες για προβλήματα μηχανικής μάθησης στον τομέα της υγείας. Πιο συγκεκριμένα, βλέπουμε στον παρακάτω πίνακα ότι το μοντέλο μας ξεπερνάει το μοντέλο VGGNet και CNN των Lopez κ.α. [23] με ευαισθησία 78.66%. Κάτι τέτοιο ήταν αναμενόμενο, καθώς στην έρευνα αυτή δεν είχε χρησιμοποιηθεί τμηματοποίηση εικόνων. Ωστόσο, τα αποτελέσματά μας είναι καλύτερα και από το CNN που προτάθηκε από το Institute of Electrical and Electronics Engineers Inc. [24] το οποίο χρησιμοποιεί τμηματοποίηση των εικόνων και παρουσιάζει ευαισθησία 81% και ειδικότητα 80%, όπως και των Codella κ.α. [26]. Ως προς τα μοντέλα που παρουσιάζονται στα [27], [28] τα αποτελέσματά μας είναι ελαφρώς χειρότερα, με το μοντέλο [29] να δίνει τις καλύτερες τιμές σε ευαισθησία και ειδικότητα, 98.33% και 98.93% αντίστοιχα.

Models	Sensitivity	Specification
Fine-tuning -VGGNet	0,7866	-

5-layer CNN	0,81	0,8
Fully convolutional residual network - deep residual network	0,5407	0,941
Deep Learning Ensemble	0,693	0,836
GrabCut - Adaptive Neuro-Fuzzy classifier (ANFC)	0,9340	0,9870
AlexNet - ECOC SVM	0,989	0,9417
AlexNet - softmax	0,9833	0,9893
EfficientNet-B0	0,95	0,87

4

Ανάπτυξη εφαρμογής

Για τη δημιουργία της εφαρμογής, χρειάστηκε να συνδυάσουμε τεχνολογίες προκειμένου να ενσωματώσουμε μεθόδους μηχανικής μάθησης σε εφαρμογή κινητού Android.

4.1 Εργαλεία & Βιβλιοθήκες

4.1.1 Android Studio

Το Android Studio είναι ένα ολοκληρωμένο προγραμματιστικό περιβάλλον (IDE) για ανάπτυξη εφαρμογών στην πλατφόρμα Android. Το Android Studio είναι διαθέσιμο ελεύθερα με την άδεια Apache License 2.0[39]. Βασισμένο στο λογισμικό της JetBrains' IntelliJ IDEA, το Android Studio σχεδιάστηκε αποκλειστικά για προγραμματισμό Android. Χρησιμοποιήθηκε για την ανάπτυξη του κώδικα της εφαρμογής μας σε γλώσσες Java και Kotlin.

4.1.2 Python Flask

Το Flask είναι ένα micro – περιβάλλον το οποίο χρησιμοποιείται για την ανάπτυξη διαδικτυακών εφαρμογών με βάση τη γλώσσα Python. Micro σημαίνει ότι περιλαμβάνει τις βασικές λειτουργικότητες και αφήνει πιο σύνθετες λειτουργίες όπως η αυθεντικοποίηση σε πρόσθετα (extensions), σε αντίθεση με πιο σύνθετα περιβάλλοντα όπως το Django που διαθέτουν ένα ολοκληρωμένο σύνολο λειτουργιών χωρίς να απαιτούνται πρόσθετα. Το Flask χρησιμοποιήθηκε για να μπορέσουμε να στήσουμε έναν τοπικό server στον υπολογιστή μας, ο οποίος τρέχει στη διεύθυνση IP του υπολογιστή μας.

4.1.3 Retrofit 2

Το Retrofit 2 είναι ένας εξαιρετικά χρήσιμος πελάτης HTTP για Android που επιτρέπει στις εφαρμογές να συνδέονται με ένα API Ιστού με ασφάλεια και πολύ λιγότερο κώδικα. Στην δική μας περίπτωση, βοηθάει στην διαχείριση των JSON responses από την εφαρμογή, ώστε να χρησιμοποιηθούν οι απαντήσεις του server και να οπτικοποιηθούν για τον χρήστη, όπως θα περιγράψουμε και παρακάτω.

4.1.4 HTTP POST requests

Το POST είναι η μέθοδος HTTP που έχει σχεδιαστεί για την αποστολή φορτίων δεδομένων σε διακομιστή από έναν καθορισμένο πόρο. Οι περισσότερες κοινές φόρμες HTML στον Ιστό λειτουργούν χρησιμοποιώντας αυτήν τη μέθοδο αιτήματος. Συνήθως μεταδίδει σχετικά μικρά φορτία δεδομένων σε έναν δέκτη. Αυτή η μέθοδος επιτρέπει την αποστολή δεδομένων ως πακέτο σε ξεχωριστή επικοινωνία με το σενάριο επεξεργασίας. Αυτό σημαίνει ότι τα δεδομένα που αποστέλλονται μέσω της μεθόδου POST δεν θα είναι ορατά στη διεύθυνση URL, καθώς οι παράμετροι δεν αποστέλλονται μαζί με το URI. Στην εργασία μας χρησιμοποιήσαμε POST requests για να στέλνουμε εικόνες για κατηγοριοποίηση στον server μας.

4.1.5 Ngrok

Το εργαλείο Ngrok εκθέτει τοπικούς διακομιστές πίσω από NAT και τείχη προστασίας στο δημόσιο διαδίκτυο μέσω ασφαλών σηράγγων. Στην εργασία μας, χρησιμοποιήθηκε για την αντιστοίχιση της τοπικής IP του υπολογιστή μας σε μία διεύθυνση στην οποία το κινητό στέλνει HTTP requests.

4.2 Μοντέλο Μηχανικής Μάθησης

Στο προηγούμενο κεφάλαιο παρουσιάσαμε ένα μοντέλο μηχανικής μάθησης που εκπαιδεύσαμε μόνοι μας, μέσω μεταφοράς μάθησης. Ωστόσο, προτιμήσαμε να ενσωματώσουμε στην εφαρμογή μας, μετά από έρευνα, ένα μοντέλο που έχει εκπαιδευτεί σε ένα μεγαλύτερο dataset και τα αποτελέσματά του ίσως είναι πιο ακριβή.

Το δίκτυο που χρησιμοποιήθηκε ονομάζεται MelaNet και αποτελεί ένα μοντέλο βαθιάς μάθησης (deep learning) για την αναγνώριση καρκίνου του δέρματος που χρησιμοποιεί REST API endpoints. Το μοντέλο δημοσιεύθηκε από τους Zunair, Hasib & A. Ben Hamza το 2020,

και δημιουργήθηκε χρησιμοποιώντας τη μέθοδο της μεταφοράς μάθησης (Transfer Learning) [40].

4.2.1 Μοντέλο

Το μοντέλο ταξινόμησης MelaNet που χρησιμοποιήσαμε, κάνει χρήση του προ-εκπαιδευμένου συνελκτικού νευρωνικού δικτύου VGG-16. Το δίκτυο VGG-16 αποτελείται από 16 επίπεδα με βάρη: 13 συνελκτικά στρώματα και 3 πλήρως συνδεδεμένα στρώματα. Η αρχιτεκτονική VGGGAP αποτελείται από πέντε μπλοκ συνελκτικών στρωμάτων, που ακολουθούνται από ένα επίπεδο global average pooling (GAP). Κάθε ένα από το πρώτο και το δεύτερο συνελκτικό τμήμα αποτελείται από δύο συνελκτικά στρώματα με φίλτρα 64 και 128, αντίστοιχα. Ομοίως, καθένα από το τρίτο, τέταρτο και πέμπτο συνελκτικό μπλοκ αποτελείται από τρία συνελκτικά επίπεδα με φίλτρα 256, 512 και 512, αντίστοιχα. Το επίπεδο GAP, το οποίο χρησιμοποιείται ευρέως σε εργασίες ταξινόμησης, υπολογίζει τη μέση απόδοση κάθε χάρτη δυνατοτήτων στο προηγούμενο επίπεδο και βοηθά στην ελαχιστοποίηση της υπερφόρτωσης μειώνοντας το σύνολο του αριθμού παραμέτρων στο μοντέλο. Το GAP μετατρέπει έναν χάρτη λειτουργιών σε έναν μόνο αριθμό, λαμβάνοντας τον μέσο όρο των αριθμών σε αυτόν τον χάρτη χαρακτηριστικών. Παρόμοια με τα ανώτατα επίπεδα συγκέντρωσης, τα επίπεδα GAP δεν έχουν εκπαιδευτικές παραμέτρους και χρησιμοποιούνται για τη μείωση των χωρικών διαστάσεων τρισδιάστατου τανυστή. Το στρώμα GAP ακολουθείται από ένα μόνο στρώμα FC με λειτουργία softmax που αποδίδει τις πιθανότητες των προβλεπόμενων τάξεων.

Λόγω της μη διαθεσιμότητας συνόλων δεδομένων που αποτελούνται από συζευγμένα παραδείγματα για την ανίχνευση μελανώματος, χρησιμοποιήθηκαν cycle-consistent ανταγωνιστικά δίκτυα (CycleGAN), μια τεχνική που περιλαμβάνει την αυτόματη εκπαίδευση μοντέλων μετάφρασης εικόνας σε εικόνα χωρίς ζευγάρια παραδειγμάτων.

Ο τελικός αλγόριθμος που χρησιμοποιήθηκε για τη δημιουργία του μοντέλου φαίνεται παρακάτω:

Algorithm 1 MelaNet classifier

Input: Training set $\mathcal{D} = \{(\mathbf{I}_1, y_1), \dots, (\mathbf{I}_n, y_n)\}$ of dermo-
scopic images, where y_i is a class label of the input \mathbf{I}_i .

Output: Vector \hat{y} containing predicted class labels.

```
1: for  $i = 1$  to  $n$  do
2:   Group each lesion image according to class label.
3:   Resize each image to  $256 \times 256 \times 3$ .
4: end for
5: Balance the inter-class data samples.
6: Train CycleGAN on unpaired and balanced interclass data.
7: for  $i = 1$  to  $n$  do
8:   if class label benign then
9:     Translate to malignant using the generator network
10:  else
11:    pass
12:  end if
13: end for
14: Merge synthetic under-represented class outputs and original training set.
15: Shuffle.
16: Train VGG-GAP on the balanced training set
17: Evaluate the model on the test set and generate predicted class labels.
```

Ουσιαστικά, η είσοδος είναι ένα σετ από εικόνες δερματικών βλαβών, μαζί με τις σχετικές ετικέτες κλάσης. Στο πρώτο στάδιο, οι διαφορετικές κατηγορίες ομαδοποιούνται (π.χ. για δυαδική ταξινόμηση, έχουμε δύο ομάδες) και αλλάζουμε το μέγεθος κάθε εικόνας σε $256 \times 256 \times 3$. Στη συνέχεια, εξισορροπούν τα δείγματα δεδομένων μεταξύ τάξεων με τη μέθοδο undersampling. Εκπαιδεύουμε το CycleGAN για να μάθουμε μια συνάρτηση της διακύμανσης μεταξύ των

δύο ομάδων. Εφαρμόζουμε το CycleGAN στα δείγματα τάξης που παρουσιάζονται υπερβολικά κι έτσι αποκτούμε ένα ισορροπημένο σύνολο δεδομένων, που αποτελείται από πρωτότυπα δεδομένα εκπαίδευσης και δημιουργημένα δεδομένα. Στο δεύτερο στάδιο, χρησιμοποιούμε τον ταξινομητή VGG-GAP με τη λειτουργία εστιακής απώλειας.

4.2.2 Dataset

Το μοντέλο αξιολογήθηκε στο σύνολο δεδομένων ISIC-2016, [41] μια δημόσια προσβάσιμη πρόκληση αναφοράς δερματολογίας για την ανάλυση βλάβης του δέρματος προς την ανίχνευση μελανώματος [42], η οποία αξιοποιεί τις εικόνες από το αρχείο International Skin Imaging Collaboration (ISIC). Το σύνολο δεδομένων περιέχει ένα αντιπροσωπευτικό μείγμα εικόνων τόσο κακοηθών όσο και καλοήθων βλαβών του δέρματος, οι οποίες χωρίστηκαν τυχαία σε σύνολα train - test, με 900 εικόνες στο σετ train και 379 εικόνες στο σετ test, αντίστοιχα. Αξίζει να σημειωθεί ότι στο train set, υπάρχουν 727 καλοήθεις περιπτώσεις και μόνο 173 κακοήθεις περιπτώσεις, με αποτέλεσμα μια αναλογία 1:4. Οι δύο κατηγορίες έχουν υψηλή οπτική ομοιότητα, καθιστώντας το έργο της ανίχνευσης μελανώματος αρκετά δύσκολη. Σημειώστε ότι υπάρχει υψηλή διακύμανση μεταξύ των κακοήθων δειγμάτων. Αυτές οι παραλλαγές περιλαμβάνουν το χρώμα, την υφή και το σχήμα. Από την άλλη πλευρά, είναι σημαντικό να επισημανθεί ότι τα καλοήθη δείγματα δεν είναι οπτικά πολύ διαφορετικά, και ως εκ τούτου παρουσιάζουν χαμηλή διακύμανση μεταξύ τους.

4.2.3 Απόδοση


Η αποτελεσματικότητα ταξινομητή του μοντέλου που χρησιμοποιήσαμε (MelaNet) αξιολογείται διενεργώντας μια ολοκληρωμένη σύγκριση με τις βασικές μεθόδους, χρησιμοποιώντας διάφορες μετρικές αξιολόγησης απόδοσης. Περιγράψαμε νωρίτερα την ευαισθησία και τα False Negative results. Η χαρακτηριστική καμπύλη χειριστή δέκτη - Receiver Operator Characteristic (ROC) είναι μια μετρική αξιολόγησης για δυαδικά προβλήματα ταξινόμησης. Είναι μια καμπύλη πιθανότητας που σχεδιάζει το TPR (True Positive Rate) έναντι FPR (False Positive Rate) σε διάφορες τιμές κατωφλίου και ουσιαστικά διαχωρίζει το «σήμα» από το «θόρυβο». Η περιοχή κάτω από την καμπύλη - Area Under the Curve (AUC) είναι το μέτρο της ικανότητας ενός ταξινομητή να διακρίνει μεταξύ τάξεων, και χρησιμοποιείται ως σύνοψη της καμπύλης ROC. Όσο υψηλότερη είναι η AUC, τόσο καλύτερη είναι η απόδοση του μοντέλου στη διάκριση μεταξύ τάξεων.

Table 1: Classification evaluation results of MelaNet and baseline methods. Boldface numbers indicate the best performance.

Method	Performance Measures		
	AUC (%)	Sensitivity (%)	FN
Gutman <i>et al.</i>	80.40	50.70	–
Yu <i>et al.</i> (without segmentation)	78.20	42.70	–
Yu <i>et al.</i> (with segmentation)	78.30	54.70	–
VGG-GAP	79.08	84.46	55
VGG-GAP + Augment-5x	78.81	85.34	51
VGG-GAP + Augment-10x	79.56	86.09	47
MelaNet (<i>ours</i>)	81.18	91.76	22

Τα αποτελέσματα σύγκρισης της απόδοσης και οι βασικές μέθοδοι που χρησιμοποιούν: AUC, FN και Sensitivity απεικονίζονται παρακάτω:

Παρατηρούμε ότι η προσέγγιση που χρησιμοποιήσαμε ξεπερνά τα υπόλοιπα μοντέλα, επιτυγχάνοντας AUC 81,18% και ευαισθησία 91,76% με βελτιώσεις απόδοσης 2,1% και 7,3% σε σχέση με το VGG-GAP. Είναι ενδιαφέρον ότι το MelaNet αποδίδει τον μικρότερο αριθμό ψευδών αρνητικών, τα οποία μειώθηκαν κατά περισσότερο από 50% σε σύγκριση με τις βασικές μεθόδους, δηλαδή το MelaNet έπιασε περιπτώσεις ασθενών που δεν θα είχαν εντοπιστεί από τα υπόλοιπα μοντέλα. Αυτή είναι μια σημαντική απόδοση στο δυναμικό πρόωρης ανίχνευσης μελανώματος, αν και το MelaNet εκπαιδεύτηκε σε μόνο 1627 δείγματα αποτελούμενα από 900 εικόνες από το αρχικό σύνολο δεδομένων και 727 συνθετικές εικόνες (καλοήθειες και κακοήθειες) που ελήφθησαν μέσω γενετικής εκπαίδευσης αντιπαραθέσεων.



4.3 Ανάπτυξη Εφαρμογής Android

Η εφαρμογή μας αναπτύχθηκε στο Android Studio, σε γλώσσες Java & Kotlin.

4.3.1 Ενσωμάτωση Μηχανικής Μάθησης στην Εφαρμογή

Όσον αφορά τη σύνδεση του μοντέλου μηχανικής μάθησης με την εφαρμογή Android, εξετάστηκαν διάφοροι τρόποι επίτευξης αυτού του στόχου. Συγκεκριμένα, υπήρχαν δύο επιλογές:

- ✓ Το μοντέλο μπορούσε να ενσωματωθεί πλήρως στην εφαρμογή κινητού και η όλη διαδικασία κατηγοριοποίησης της εικόνας μας να εκτελείται από την ίδια τη συσκευή
- ✓ Το μοντέλο μπορούσε να τρέχει σε έναν εξωτερικό server, στον οποίο η εφαρμογή θα στέλνει την εικόνα και θα περιμένει να λάβει απάντηση για τα τελικά αποτελέσματα.

Συγκεκριμένα εξετάστηκαν βιβλιοθήκες όπως η onnxruntime, DNNLibrary, tf-lite, οι οποίες ενδείκνυνται για χρήση μηχανικής μάθησης σε εφαρμογές κινητού, ενσωματώνοντας το μοντέλο στην ίδια την εφαρμογή. Ωστόσο, το συμπέρασμα που προέκυψε είναι ότι θεωρείται αρχιτεκτονικά ορθότερο η κινητή συσκευή να μην επιβαρυνθεί με ένα νευρωνικό δίκτυο που θα απαιτεί αρκετούς από τους πόρους της. Αντίθετα, η επιλογή που προτιμάται και από Android Developers για εφαρμογές μεγαλύτερου βεληνεκούς, είναι να χρησιμοποιείται κάποιος εξωτερικός server στον οποίο τρέχει το μοντέλο μηχανικής μάθησης. Αυτή είναι και η μέθοδος που ακολουθήσαμε.

4.3.2 Σύνδεση Μοντέλου και Εφαρμογής

Στην εφαρμογή που αναπτύξαμε, επιλέξαμε να στέλνουμε HTTP POST requests, σε κάποιο εξωτερικό server, ο οποίος θα είναι συνεχώς ανοιχτός και θα τρέχει με το μοντέλο μηχανικής μάθησης. Χρησιμοποιήσαμε το microframework Flask της Python, το οποίο μας επέτρεψε με τα κατάλληλα scripts να στήσουμε έναν server με διεύθυνση <http://localhost:8000>. Για τη λήψη της απάντησης αυτών των requests χρησιμοποιήθηκαν python scripts, τα οποία μας επιτρέπουν να στέλνουμε μέσω του request δεδομένα, στην συγκεκριμένη περίπτωση εικόνες, και να λαμβάνονται ως απάντηση JSON responses. Επίσης έγινε χρήση του Retrofit 2 ως REST Client για Android, το οποίο βοηθάει στην διαχείριση των JSON responses από την εφαρμογή, ώστε να χρησιμοποιηθούν οι απαντήσεις του server και να οπτικοποιηθούν για τον χρήστη. Αντιμετωπίσαμε, επιπλέον, το πρόβλημα ότι το κινητό δεν μπορεί να στέλνει requests

στην διεύθυνση <http://localhost:8000>, καθώς την αναγνωρίζει σαν την δική του τοπική διεύθυνση, χρησιμοποιώντας το εργαλείο ngrok που περιεγράφηκε παραπάνω.

4.3.3 Ανάπτυξη εφαρμογής

Ως προς την ανάπτυξη της εφαρμογής, χρησιμοποιήσαμε το Android Studio. Δοκιμάζαμε την εφαρμογή σε φυσική συσκευή, με σύνδεση μέσω καλωδίου με τον υπολογιστή. Υπήρχε η επιλογή δοκιμής σε emulator, όμως δεν φάνηκε ιδιαίτερα αποδοτική καθώς επιβάρυνε εξαιρετικά τον υπολογιστή του developer και ταυτόχρονα δεν μπορούσε να δοκιμαστεί το feature της λήψης φωτογραφίας από τη συσκευή.

5

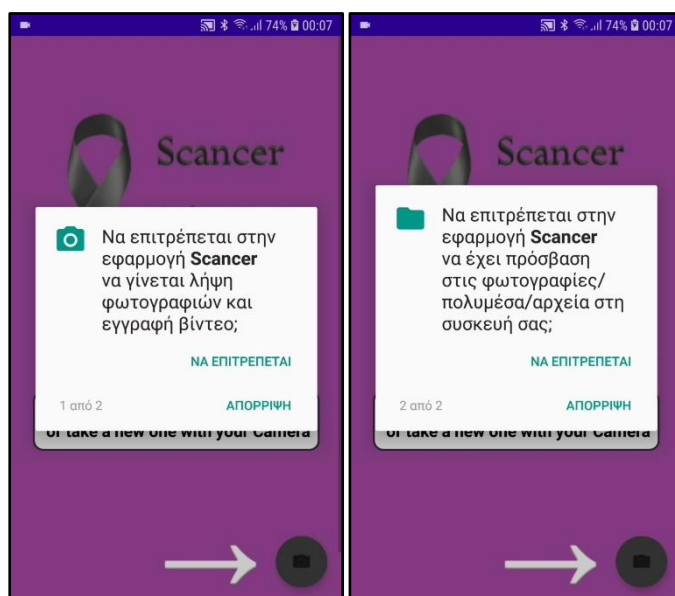
Αποτελέσματα

5.1 Εφαρμογή


Στόχος μας ήταν η ανάπτυξη μιας απλής εφαρμογής, φιλικής προς τον, δεδομένου ότι προορίζεται για άτομα όλων των ηλικιών, καθώς πλέον το μεγαλύτερο ποσοστό των ανθρώπων ξέρει να χειρίζεται smartphones, ανεξαρτήτου ηλικίας. Συγκεκριμένα ονομάστηκε Scancer , καθώς πρόκειται για έναν σαρωτή καρκίνου (scan cancer).

5.2 Τρόπος Χρήσης



Για τη λειτουργία της εφαρμογής απαιτείται η λήψη φωτογραφίας ή η επιλογή φωτογραφίας από τα δεδομένα της κινητής συσκευής, αφού πρώτα επιτραπεί η πρόσβαση στην κάμερα και τη συλλογή του κινητού.




Κατά την εκκίνηση της εφαρμογής εμφανίζεται το λογότυπο της σχολής μας:



Η διαδικασία επιλογής φαίνεται στις παρακάτω εικόνες:



Μετά την επιλογή, ο χρήστης περιμένει λίγα δευτερόλεπτα για την αποστολή του αιτήματος:

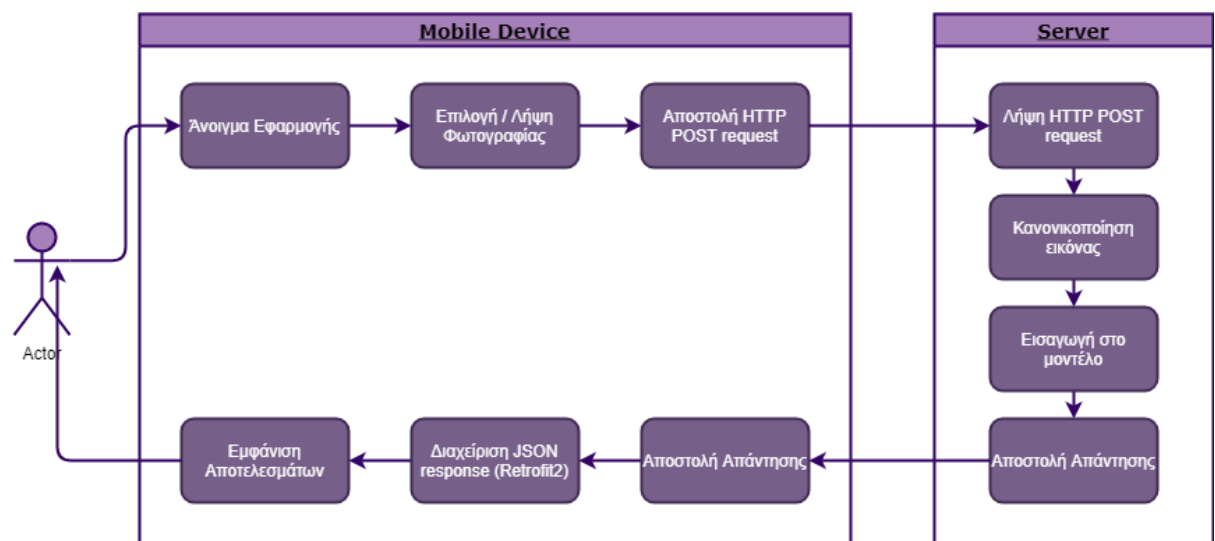


Λαμβάνει την απάντηση σε μορφή κειμένου, που δείχνει την πιθανότητα η εικόνα που επέλεξε να απεικονίζει δερματική βλάβη ή όχι:



5.3 Διάγραμμα Χρήσης

Παρουσιάζουμε, λοιπόν, το συνολικό διάγραμμα χρήσης της εφαρμογής μας:



Ουσιαστικά ο χρήστης ανοίγει την εφαρμογή και επιλέγει μια ήδη υπάρχουσα φωτογραφία από το κινητό του ή λαμβάνει μια νέα φωτογραφία χρησιμοποιώντας την κάμερα της συσκευής. Η φωτογραφία αυτή στέλνεται μέσω HTTP POST request στον server, όπως περιεγράφηκε παραπάνω, όπου και γίνεται κανονικοποίηση της εικόνας για να μετατραπεί στην επιθυμητή μορφή για την είσοδο στο νευρωνικό. Η κανονικοποιημένη πλέον εικόνα

εισάγεται στο μοντέλο μηχανικής μάθησης, το οποίο στέλνει την δυαδική απάντηση πίσω στη συσκευή σε μορφή JSON. Η εφαρμογή διαχειρίζεται την απάντηση με τη βοήθεια του Retrofit 2 και την εμφανίζει στο χρήστη.

6

Συμπεράσματα - Επίλογος

6.1 Συμπεράσματα

Η εφαρμογή μας αναπτύχθηκε στα πλαίσια εργασίας και σε καμία περίπτωση δεν πρέπει να αντικαταστήσει ήδη αναγνωρισμένες μεθόδους διάγνωσης καρκίνου του δέρματος. Ωστόσο, θεωρούμε ότι μια τέτοια εφαρμογή, σωστά μελετημένη και σε συνεργασία με ειδικούς στον τομέα της υγείας, θα μπορούσε να φανεί κρίσιμος αρωγός στην προσπάθεια έγκαιρης διάγνωσης καρκίνου του δέρματος και ως εκ τούτου στην επιτυχή αντιμετώπισή του.

6.2 Μελλοντικές Επεκτάσεις

Στα πλαίσια του μαθήματος και εξαιτίας του μικρού χρονικού διαστήματος που μας δόθηκε, καταφέραμε να εκπαιδύσουμε ένα μόνο μοντέλο μηχανικής μάθησης. Ωστόσο θα μας ενδιέφερε, έχοντας τον απαραίτητο χρόνο, να ασχοληθούμε παραπάνω με την συγκεκριμένη εφαρμογή και να δοκιμάσουμε οι ίδιοι την απόδοση και άλλων μοντέλων με μεταφορά μάθησης, ίσως χρησιμοποιώντας κι άλλα datasets, για να μπορέσουμε να αποκτήσουμε μια πιο ολοκληρωμένη εικόνα και να καταλήξουμε στο ακριβέστερο μοντέλο. Η συλλογή ενός μεγαλύτερου και πιθανώς καλύτερα ισορροπημένου συνόλου δεδομένων είναι σχεδόν βέβαιο ότι θα οδηγούσε στην αύξηση της απόδοσης των μοντέλων εκπαίδευσης. Ακόμα, θα θέλαμε να αφιερώσουμε περισσότερο χρόνο και προσοχή στην ίδια την εφαρμογή, προσθέτοντας ίσως κάποιο προσωπικό λογαριασμό για κάθε χρήστη και αποθήκευση του ιστορικού του, συνδυάζοντας κι άλλα ιατρικά στοιχεία για εκείνον.

7

Βιβλιογραφία

- [1] C. Dr. Tzeremias, “Καρκίνος δέρματος, Μελάνωμα | Ολόσωμη Χαρτογράφηση | Dr. Tzeremias.” <https://www.tzermias.gr/καρκινος-δερματος/>.
- [2] Υπουργείο Υγείας, “Ελληνική εβδομάδα κατά του καρκίνου του δέρματος - Νέα - Υπουργείο Υγείας,” 2013. <https://www.moh.gov.gr/articles/news/1720-ellhnikh-ebdomada-kata-toy-karkinoy-toy-dermatos>.
- [3] Άγιος Σάββας - Γενικό Αντικαρκινικό / Ογκολογικό Νοσοκομείο Αθηνών, “Καρκίνος δέρματος | Πρόληψη του καρκίνου.” <http://www.agsavvas-hosp.gr/Μάθεγιατονκαρκίνο/Πρόληψη/Πρωτογενήςπρόληψη/Καρκίνοςδέρματος.aspx>.
- [4] Χριστίνα Γκίντζου, “Καρκίνος του δέρματος | Χριστίνα Γκίντζου | Δερματολόγος - Αφροδισιολόγος.” <https://cgderma.gr/ipiresies/kliniki-dermatologia/karkinos-toy-dermatos/>.
- [5] Γεώργιος Θ. Αραβανης, “Καρκίνος Δέρματος: Αίτια, Συμπτώματα & Θεραπεία | Γ. Αραβανής.” <https://www.aravanisplasticsurgery.gr/karkinos-dermatos-therapeia#diagnosi>.
- [6] “UMSkinCheck App | Skin Check App | Skin Cancer Prevention | University of Michigan Comprehensive Cancer Center.” <https://www.rogelcancercenter.org/skin-cancer/melanoma/prevention/app>.
- [7] M. E. Celebi *et al.*, “A methodological approach to the classification of dermoscopy images,” *Comput. Med. Imaging Graph.*, vol. 31, no. 6, pp. 362–373, Sep. 2007, doi: 10.1016/j.compmedimag.2007.01.003.
- [8] G. Schaefer, B. Krawczyk, M. E. Celebi, and H. Iyatomi, “An ensemble classification approach for melanoma diagnosis,” *Memetic Comput.*, vol. 6, no. 4, pp. 233–240, Dec.

- 2014, doi: 10.1007/s12293-014-0144-8.
- [9] L. Yu, H. Chen, Q. Dou, J. Qin, and P. A. Heng, "Automated Melanoma Recognition in Dermoscopy Images via Very Deep Residual Networks," *IEEE Trans. Med. Imaging*, vol. 36, no. 4, pp. 994–1004, Apr. 2017, doi: 10.1109/TMI.2016.2642839.
 - [10] H.-C. Shin *et al.*, "Deep Convolutional Neural Networks for Computer-Aided Detection: CNN Architectures, Dataset Characteristics and Transfer Learning," *IEEE Trans. Med. Imaging*, vol. 35, no. 5, pp. 1285–1298, Feb. 2016, Accessed: May 22, 2021. [Online]. Available: <http://arxiv.org/abs/1602.03409>.
 - [11] S. Min and J. Kim, "ML-based Interactive Data Visualization System for Diversity and Fairness Issues," *Int. J. Contents*, vol. 15, no. 4, pp. 1–7, 2019, doi: 10.5392/IJoC.2019.15.4.001.
 - [12] J. Y. Zhu, T. Park, P. Isola, and A. A. Efros, "Unpaired Image-to-Image Translation Using Cycle-Consistent Adversarial Networks," in *Proceedings of the IEEE International Conference on Computer Vision*, Dec. 2017, vol. 2017-October, pp. 2242–2251, doi: 10.1109/ICCV.2017.244.
 - [13] K. Matsunaga, A. Hamada, A. Minagawa, and H. Koga, "Image classification of melanoma, nevus and seborrheic keratosis by deep neural network ensemble," *arXiv*, arXiv, Mar. 08, 2017.
 - [14] A. Ben-Cohen, E. Klang, S. P. Raskin, M. M. Amitai, and H. Greenspan, "Virtual PET Images from CT Data Using Deep Convolutional Networks: Initial Results," *Lect. Notes Comput. Sci. (including Subser. Lect. Notes Artif. Intell. Lect. Notes Bioinformatics)*, vol. 10557 LNCS, pp. 49–57, Jul. 2017, doi: 10.1007/978-3-319-68127-6_6.
 - [15] G. Yang *et al.*, "DAGAN: Deep De-Aliasing Generative Adversarial Networks for Fast Compressed Sensing MRI Reconstruction," *IEEE Trans. Med. Imaging*, vol. 37, no. 6, pp. 1310–1321, Jun. 2018, doi: 10.1109/TMI.2017.2785879.
 - [16] J. M. Wolterink, A. M. Dinkla, M. H. F. Savenije, P. R. Seevinck, C. A. T. van den Berg, and I. Isgum, "Deep MR to CT Synthesis using Unpaired Data," *Lect. Notes Comput. Sci. (including Subser. Lect. Notes Artif. Intell. Lect. Notes Bioinformatics)*, vol. 10557 LNCS, pp. 14–23, Aug. 2017, Accessed: May 22, 2021. [Online]. Available: <http://arxiv.org/abs/1708.01155>.
 - [17] T. Russ *et al.*, "Synthesis of CT images from digital body phantoms using CycleGAN," *Int. J. Comput. Assist. Radiol. Surg.*, vol. 14, no. 10, pp. 1741–1750, Oct. 2019, doi:

- 10.1007/s11548-019-02042-9.
- [18] M. T. Shaban, C. Baur, N. Navab, and S. Albarqouni, “StainGAN: Stain Style Transfer for Digital Histological Images,” *Proc. - Int. Symp. Biomed. Imaging*, vol. 2019-April, pp. 953–956, Apr. 2018, Accessed: May 22, 2021. [Online]. Available: <http://arxiv.org/abs/1804.01601>.
 - [19] T. de Bel, M. Hermsen, R. Jesper Kers, J. van der Laak, and G. Litjens, “Stain-Transforming Cycle-Consistent Generative Adversarial Networks for Improved Segmentation of Renal Histopathology,” PMLR, May 2019. Accessed: May 22, 2021. [Online]. Available: <http://proceedings.mlr.press/v102/de-bel19a.html>.
 - [20] A. Bissoto, F. Perez, E. Valle, and S. Avila, “Skin Lesion Synthesis with Generative Adversarial Networks,” *Lect. Notes Comput. Sci. (including Subser. Lect. Notes Artif. Intell. Lect. Notes Bioinformatics)*, vol. 11041 LNCS, pp. 294–302, Feb. 2019, doi: 10.1007/978-3-030-01201-4_32.
 - [21] I. S. Ali, M. F. Mohamed, and Y. B. Mahdy, “Data augmentation for skin lesion using self-attention based progressive generative adversarial network,” *arXiv*. arXiv, Oct. 25, 2019.
 - [22] J. P. Cohen, M. Luck, and S. Honari, “Distribution Matching Losses Can Hallucinate Features in Medical Image Translation,” *Lect. Notes Comput. Sci. (including Subser. Lect. Notes Artif. Intell. Lect. Notes Bioinformatics)*, vol. 11070 LNCS, pp. 529–536, May 2018, Accessed: May 22, 2021. [Online]. Available: <http://arxiv.org/abs/1805.08841>.
 - [23] A. Romero Lopez, X. Giro-I-Nieto, J. Burdick, and O. Marques, “Skin lesion classification from dermoscopic images using deep learning techniques,” in *Proceedings of the 13th IASTED International Conference on Biomedical Engineering, BioMed 2017*, Apr. 2017, pp. 49–54, doi: 10.2316/P.2017.852-053.
 - [24] E. Nasr-Esfahani *et al.*, “Melanoma detection by analysis of clinical images using convolutional neural network,” in *Proceedings of the Annual International Conference of the IEEE Engineering in Medicine and Biology Society, EMBS*, Oct. 2016, vol. 2016-Octob, pp. 1373–1376, doi: 10.1109/EMBC.2016.7590963.
 - [25] L. Yu, H. Chen, Q. Dou, J. Qin, and P. A. Heng, “Automated Melanoma Recognition in Dermoscopy Images via Very Deep Residual Networks,” *IEEE Trans. Med. Imaging*, vol. 36, no. 4, pp. 994–1004, Apr. 2017, doi: 10.1109/TMI.2016.2642839.

- [26] N. Codella *et al.*, “Deep Learning Ensembles for Melanoma Recognition in Dermoscopy Images,” *IBM J. Res. Dev.*, vol. 61, no. 4, Oct. 2016, Accessed: May 29, 2021. [Online]. Available: <http://arxiv.org/abs/1610.04662>.
- [27] M. Yacin Sikkandar, B. A. Alrasheadi, N. B. Prakash, G. R. Hemalakshmi, A. Mohanarathinam, and K. Shankar, “Deep learning based an automated skin lesion segmentation and intelligent classification model,” *J. Ambient Intell. Humaniz. Comput.*, vol. 12, no. 3, pp. 3245–3255, Mar. 2021, doi: 10.1007/s12652-020-02537-3.
- [28] U. O. Dorj, K. K. Lee, J. Y. Choi, and M. Lee, “The skin cancer classification using deep convolutional neural network,” *Multimed. Tools Appl.*, vol. 77, no. 8, pp. 9909–9924, Apr. 2018, doi: 10.1007/s11042-018-5714-1.
- [29] K. M. Hosny, M. A. Kassem, and M. M. Foad, “Skin Cancer Classification using Deep Learning and Transfer Learning,” in *2018 9th Cairo International Biomedical Engineering Conference, CIBEC 2018 - Proceedings*, Feb. 2019, pp. 90–93, doi: 10.1109/CIBEC.2018.8641762.
- [30] T. Mendonca, P. M. Ferreira, J. S. Marques, A. R. S. Marcal, and J. Rozeira, “PH2 - A dermoscopic image database for research and benchmarking,” in *Proceedings of the Annual International Conference of the IEEE Engineering in Medicine and Biology Society, EMBS*, 2013, pp. 5437–5440, doi: 10.1109/EMBC.2013.6610779.
- [31] L. Breiman, T. Mitchell, T. Poggio, N. Sharkey, and J. Shavlik, “Post-NIPS*95 Workshop on Transfer in Inductive Systems.” 1995, Accessed: May 29, 2021. [Online]. Available: http://plato.acadiau.ca/courses/comp/dsilver/NIPS95_LTL/transfer.workshop.1995.html.
- [32] F. Zhuang *et al.*, “A Comprehensive Survey on Transfer Learning,” *Proceedings of the IEEE*, vol. 109, no. 1. Institute of Electrical and Electronics Engineers Inc., pp. 43–76, Jan. 01, 2021, doi: 10.1109/JPROC.2020.3004555.
- [33] E. S. Olivas, J. D. M. Guerrero, M. Martinez Sober, J. R. Magdalena Benedito, and A. J. Serrano López, *Handbook of research on machine learning applications and trends: Algorithms, methods, and techniques*. IGI Global, 2009.
- [34] “Welcome To Colaboratory - Colaboratory.” <https://colab.research.google.com/notebooks/intro.ipynb#recent=true> (accessed May 22, 2021).

- [35] “Keras: the Python deep learning API.” <https://keras.io/> (accessed May 22, 2021).
- [36] M. Tan and Q. V. Le, “EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks,” *36th Int. Conf. Mach. Learn. ICML 2019*, vol. 2019-June, pp. 10691–10700, May 2019, Accessed: May 22, 2021. [Online]. Available: <http://arxiv.org/abs/1905.11946>.
- [37] T. Elsken, J. H. Metzen, and F. Hutter, “Neural Architecture Search: A Survey,” 2019. Accessed: May 22, 2021. [Online]. Available: <http://jmlr.org/papers/v20/18-598.html>.
- [38] P. L. Lagari, L. H. Tsoukalas, and I. E. Lagaris, “Variance Counterbalancing for Stochastic Large-scale Learning,” *Int. J. Artif. Intell. Tools*, vol. 29, no. 5, Aug. 2020, doi: 10.1142/S0218213020500104.
- [39] “android/src/org/jetbrains/android/AndroidPlugin.java - platform/tools/adt/idea - Git at Google.” <https://android.googlesource.com/platform/tools/adt/idea/+master/android/src/org/jetbrains/android/AndroidPlugin.java> (accessed May 22, 2021).
- [40] H. Zunair and A. Ben Hamza, “Melanoma Detection using Adversarial Training and Deep Transfer Learning,” *Phys. Med. Biol.*, vol. 65, no. 13, Apr. 2020, doi: 10.1088/1361-6560/ab86d3.
- [41] D. P. Kingma and J. Lei Ba, “ADAM: A METHOD FOR STOCHASTIC OPTIMIZATION.”
- [42] Y. Li and L. Shen, “Skin lesion analysis towards melanoma detection using deep learning network,” *Sensors (Switzerland)*, vol. 18, no. 2, Feb. 2018, doi: 10.3390/s18020556.